

Pós-Processamento Supera Retreino: Um Estudo Abrangente de Ablação da Cabeça de Normalizing Flow para Localização de Anomalias em Inspeção de Linhas de Transmissão

Teo Santos
Universidade de Brasília
Brasília, Brasil

Resumo—A localização precisa de anomalias em componentes de linhas de transmissão é essencial para a manutenção preditiva baseada em imagens aéreas de veículos não tripulados (VANTs). Modelos baseados em normalizing flows (NF), como o CFLOW-AD, aprendem a distribuição de features normais e usam a verossimilhança negativa (NLL) como score de anomalia por pixel. Embora a literatura concentre esforço em arquiteturas e treinamento, o impacto das escolhas de pós-processamento e inferência sobre a qualidade da localização permanece subexplorado. Este trabalho apresenta um estudo de ablação abrangente da cabeça de NF do pipeline SEDifferNet-CFLOW sobre as 5 classes do benchmark INSPLAD-seg, totalizando aproximadamente 24 000 medições de validação em 8 conjuntos de held-out independentes. Os resultados demonstram que a cadeia de pós-processamento — agregação crua das NLLs (*raw*), padding reflexivo exclusivo de inferência, test-time augmentation por espelhamentos e seleção de níveis de features — contribui com +0,0965 de Pixel AUROC médio sem nenhum retraining, superando qualquer intervenção de treinamento testada. A agregação *raw* isolada supera o min-max por imagem com ganho pareado de +0,0497 (positivo em 76–100% dos pares nas 5 classes). O estudo revela ainda que a hierarquia entre níveis de features é dependente da classe, que a normalização de features (*featnorm*) não generaliza entre classes (prejudicial em *yoke-suspension*: −0,0499 AUROC), e que checkpoints legados produzem diagnósticos enganosos sobre a informatividade das features. As descobertas fornecem um protocolo de implantação validado e diretrizes práticas para a comunidade de detecção de anomalias.

Palavras-chave: detecção de anomalias, normalizing flows, localização por pixel, pós-processamento, estudo de ablação, inspeção de linhas de transmissão, INSPLAD.

Index Terms—anomaly detection, normalizing flows, pixel-level localization, post-processing, ablation study, power-line inspection, INSPLAD

Abstract — Precise anomaly localization in power-line components is essential for predictive maintenance based on unmanned aerial vehicle (UAV) imagery. Normalizing-flow (NF) models such as CFLOW-AD learn the distribution of normal features and use the negative log-likelihood (NLL) as a per-pixel anomaly score. Although the literature focuses on architectures and training, the impact of post-processing and inference-time choices on localization quality remains under-explored. This work presents a comprehensive ablation study of the NF head of the SEDifferNet-CFLOW pipeline over the

5 classes of the INSPLAD-seg benchmark, totaling approximately 24 000 validation measurements across 8 independent held-out sets. Results show that the post-processing chain — raw NLL aggregation, inference-only reflective padding, flip-based test-time augmentation, and feature-level selection — contributes +0.0965 mean Pixel AUROC with zero retraining, surpassing every training intervention tested. Raw aggregation alone beats per-image min-max normalization by a paired gain of +0.0497 (positive in 76–100% of pairs across all 5 classes). The study further reveals that the feature-level hierarchy is class-dependent, that feature normalization (*featnorm*) does not generalize across classes (harmful on *yoke-suspension*: −0.0499 AUROC), and that legacy checkpoints produce misleading diagnostics about feature informativeness. The findings provide a validated deployment protocol and practical guidelines for the anomaly detection community.

Keywords: anomaly detection, normalizing flows, pixel-level localization, post-processing, ablation study, power-line inspection, INSPLAD.

I. INTRODUÇÃO

A inspeção de componentes de linhas de transmissão de energia elétrica constitui uma tarefa crítica para a manutenção da infraestrutura energética. A adoção crescente de veículos aéreos não tripulados (VANTs) para captura de imagens dessas estruturas gera volumes de dados que tornam a inspeção manual inviável, motivando o desenvolvimento de sistemas automatizados de detecção e localização de anomalias [7]. Diferentemente de benchmarks industriais amplamente utilizados como o MVTec-AD, o domínio de inspeção de linhas de transmissão apresenta desafios específicos: fundo natural dominante com alta variabilidade (vegetação), proporção de pixels anômalos extremamente baixa (0,14% a 4,6% da área), e número reduzido de amostras de treinamento com anomalias.

Métodos baseados em normalizing flows (NF) — como DifferNet [1], CFLOW-AD [2] e CS-Flow [3] — destacam-se por computar densidades exatas sobre features pré-treinadas, produzindo scores de anomalia com interpretação probabilística. Em particular, o CFLOW-AD introduziu flows condicionais por posição sobre features multi-escala, permitindo

localização por pixel ao nível da grade de features. Abordagens alternativas incluem bancos de memória como PatchCore [5] e modelos estatísticos como PaDiM [4], além de abordagens de destilação de conhecimento como RD++ [6].

Apesar do extenso esforço da comunidade em desenvolver novas arquiteturas e estratégias de treinamento, um aspecto fundamental permanece sistematicamente subexplorado: o impacto das escolhas feitas *após* o treinamento — a forma como os mapas de verossimilhança negativa (NLL) de múltiplos níveis são agregados, as transformações aplicadas na inferência, e a seleção de quais níveis de features utilizar. Na prática, essas decisões de pós-processamento são frequentemente tratadas como detalhes de implementação, herdadas de trabalhos anteriores sem validação independente. Por exemplo, a agregação `per_level_minmax` utilizada em implementações do CFLOW-AD normaliza cada mapa NLL por imagem, destruindo a escala absoluta da verossimilhança — uma operação cujo impacto raramente é questionado ou ablado.

Adicionalmente, pipelines de detecção de anomalias frequentemente acumulam divergências silenciosas entre os hiperparâmetros de treinamento e avaliação que não alteram os pesos do modelo nem geram mensagens de erro, mas modificam a função computada. Quatro divergências desse tipo foram identificadas neste estudo: clamp scale do coupling block (0,5 no treinamento vs. 2,0 na avaliação legada, alterando a faixa da escala de $\sim 2,7\times$ para $\sim 55\times$), resolução da grade de features (`out_size` 96 vs. 56), caminho de atenção utilizado para extração de features (SE vs. CBAM), e regra de agregação dos níveis. Essas divergências tornam checkpoints legados perigosamente enganosos para análises de ablação — em um caso, produziram um AUROC de 0,5583 que saltou para 0,8770 apenas pela correção do clamp.

Este trabalho apresenta um estudo de ablação abrangente da cabeça de normalizing flow condicional (CFLOW) sobre o backbone congelado SEDifferNet (AlexNet com atenção Squeeze-and-Excitation), avaliado nas 5 classes do benchmark INSPLAD-seg para inspeção de linhas de transmissão. O estudo compreende:

- Aproximadamente 24 000 medições de validação distribuídas em 8 conjuntos de held-out independentes, cobrindo 27 receitas de treinamento e grids de até 1 920 configurações de pós-processamento por head;
- Fatoração isolada dos ganhos de cada técnica por comparação pareada, com limiar de significância medido empiricamente ($\Delta = 0,0044$ AUROC por variação de split);
- Identificação de que o pós-processamento contribui com +0,0965 de Pixel AUROC médio — mais que qualquer intervenção de treinamento — sendo a agregação `raw` responsável por metade desse ganho;
- Demonstração de que a hierarquia entre níveis de features é dependente da classe, invalidando receitas universais baseadas em subconjuntos fixos;
- Evidência de que checkpoints legados produzem diagnósticos enganosos sobre a informatividade das features,

com um nível passando de AUROC 0,2583 (head legada) para 0,874 após retreino.

O artigo está organizado como segue: a Seção II situa o trabalho na literatura; a Seção III descreve a arquitetura, os fatores ablados e o protocolo experimental; a Seção IV reporta os resultados quantitativos; a Seção V interpreta as descobertas e apresenta suas implicações; e a Seção VI conclui o trabalho.

II. TRABALHOS RELACIONADOS

A. Detecção de Anomalias por Normalizing Flows

O DifferNet [1] introduziu o uso de normalizing flows sobre features multi-escala extraídas de uma AlexNet para detecção de anomalias em nível de imagem, utilizando a NLL como score. O CFLOW-AD [2] estendeu essa ideia para localização por pixel, empregando flows condicionais — um por posição espacial e por nível de features — com positional encoding senoidal 2D, blocos de acoplamento afim com *clamp* de 1,9, e agregação por probabilidade limitada (`per_level_prob`). O CS-Flow [3] e o MSFlow [8] exploraram fusão cross-scale entre os níveis, motivando a ablação de subconjuntos de níveis conduzida neste trabalho.

B. Métodos Alternativos de Localização

O PaDiM [4] modela a distribuição de features por posição com uma gaussiana multivariada, dispensando treinamento de rede. Desse trabalho, adotamos a ideia de padronizar features por canal com estatísticas de treinamento (`featnorm`). O PatchCore [5] constrói um banco de memória de patches representativos, introduzindo agregação local de vizinhança antes do scoring. O RD++ [6] utiliza destilação de conhecimento com projeção multi-escala e ruído simplex como pseudo-anomalia, além de um score composto $(AUROC_{px} + AUROC_{sp} + AUPRO)/3$ que transferimos para nosso pipeline de seleção de modelos.

C. Benchmark e Domínio de Aplicação

O INSPLAD [7] é um dataset de inspeção de linhas de transmissão capturado por VANTs, compreendendo componentes como grampos, isoladores e hastes de para-raios. A variante INSPLAD-seg fornece máscaras de segmentação por pixel para 5 classes de defeitos, com características distintivas: fundo natural dominante, variabilidade alta entre imagens, e proporção de pixels anômalos variando de 0,14% (*glass-insulator*) a 4,6% (*vari-grip*). Esse domínio apresenta desafios diferentes dos benchmarks industriais controlados como o MVTec-AD.

D. Posicionamento da Contribuição

Enquanto os trabalhos anteriores concentram-se em propor novas arquiteturas ou estratégias de treinamento, este trabalho investiga sistematicamente as escolhas de pós-processamento e inferência que ficam entre o modelo treinado e a predição final. Nosso estudo demonstra que essas escolhas — historicamente tratadas como detalhes de implementação — respondem pela maior fração do ganho de desempenho, superando qualquer intervenção de treinamento. Adicionalmente, o estudo abrange

5 classes de um mesmo benchmark sob protocolo idêntico, permitindo identificar quais descobertas generalizam e quais são específicas de classe — uma análise raramente conduzida na literatura de detecção de anomalias.

III. METODOLOGIA

A. Arquitetura do Pipeline

O pipeline de localização é composto por duas etapas: um backbone congelado para extração de features e uma cabeça de normalizing flow condicional para scoring por pixel.

1) *Backbone: SEDifferNet*: O extrator de features é uma AlexNet pré-treinada aumentada com blocos de atenção Squeeze-and-Excitation (SE) [1]. O modelo SEDifferNet foi treinado para detecção em nível de imagem; neste estudo, seus pesos são congelados e as features são extraídas em três pontos intermediários da rede:

- **L1** (64 canais, 109×109 nativo): imediatamente pós-conv1 (kernel 11×11 , stride 4, padding 2) e bloco SE `simsa1`. Apresenta campo receptivo estritamente local (11×11 px na imagem de entrada), capturando gradientes cromáticos, bordas finas e rugosidade textural de alta frequência. Alinha-se diretamente ao viés de textura (*texture bias*) característico de camadas rasas em CNNs [11].
- **L2** (192 canais, 53×53 nativo): após `pool2` e bloco SE `simsa2`. Possui campo receptivo médio ($\approx 51 \times 51$ px), codificando contornos regionais e geometrias intermediárias.
- **L3** (256 canais, 27×27 nativo): após a pilha convolucional (`conv5`) e bloco SE `simsa4`. Possui campo receptivo amplo ($> 150 \times 150$ px), codificando contexto semântico global e relações de integridade estrutural, correspondendo às representações de forma (*shape bias*) [11]. Sua grade espacial é grosseira ($\approx 16,6 \times 16,6$ px de imagem original por célula).

Os três mapas de features são reamostrados por interpolação bilinear para uma grade comum de 96×96 (`out_size`). A imagem de entrada possui dimensão canônica de 448×448 pixels.

2) *Cabeça de Normalizing Flow Condicional (CFLOW)*: Para cada nível de features, um normalizing flow condicional independente — `CondFlow` — modela a distribuição das features normais *posição a posição*. Cada `CondFlow` consiste em $K = 8$ blocos de acoplamento afim (`CondCouplingBlock`) com permutação fixa de canais entre blocos.

Cada bloco divide os canais de entrada em duas metades (x_1, x_2) e calcula:

$$y_1 = x_1 \cdot \exp(s) + t, \quad s = \tanh(\hat{s}) \cdot c_{\text{clamp}} \quad (1)$$

onde $(\hat{s}, t) = f_\theta([x_2; \text{PE}])$ é a saída de uma subrede MLP condicionada pelo positional encoding (PE) senoidal 2D de dimensão 64. O *clamp scale* $c_{\text{clamp}} = 0,5$ limita a faixa da escala a $\exp(s) \in [e^{-0,5}, e^{0,5}] \approx [0,61; 1,65]$.

O score de anomalia por posição é a NLL:

$$\text{NLL}(\mathbf{x}) = -\log p(\mathbf{x}) = \frac{1}{2} \|\mathbf{z}\|^2 + \frac{C}{2} \log(2\pi) - \sum_k \log |\det J_k| \quad (2)$$

onde $\mathbf{z}$ é a saída do flow, C é o número de canais e J_k é o jacobiano do k -ésimo bloco. Pixels com NLL alta correspondem a features que se desviam da distribuição normal aprendida.

O mapa final de anomalia é obtido agregando os mapas NLL dos níveis selecionados, aplicando upsamle bilinear para 448×448 e suavização gaussiana.

B. Fatores do Estudo de Ablação

O estudo investiga dois grupos de fatores: *treinamento* (requerem retreino da head) e *inferência* (aplicáveis sem retreino).

1) Fatores de Treinamento:

- **Normalização de features (`featnorm`)**: padronização $f' = (f - \mu) / \sigma$ por canal com estatísticas estimadas sobre imagens normais de treinamento, inspirada no PaDiM [4].
- **Clamp scale**: $c_{\text{clamp}} \in \{0,5; 1,9\}$, controlando a expressividade do bloco de acoplamento. O valor 1,9 é o original do CFLOW-AD [2].
- **Augmentation** por **rotação**: `RandomRotation(180°)` durante o treinamento.
- **Padding no treinamento (`pad_in_train`)**: reflect padding de 112 px aplicado durante o treinamento.
- **Níveis treinados (`levels`)**: subconjunto de níveis para os quais flows são treinados.

2) Fatores de Inferência:

- **Modo de agregação (`score_mode`)**: como os mapas NLL de cada nível são combinados — `raw` (soma direta), `per_level_minmax` (normalização min-max por imagem e por nível), `per_level_prob` (log-sigmoid limitada, como no CFLOW-AD), `per_level_std` (padronização com estatísticas escalares).
- **Reflect padding (`reflect_pad`)**: espelhamento da imagem de 448 para 672×672 px antes do backbone, com recorte das bordas no mapa de features. O valor 112 px é o mínimo que respeita o stride acumulado do backbone (16 px).
- **Test-time augmentation (TTA)**: média dos mapas de 4 visões simétricas (identidade, espelhamento horizontal, vertical e ambos).
- **Suavização gaussiana (σ)**: aplicada ao mapa final.
- **Seleção de níveis na inferência**: subconjunto de níveis cujos mapas NLL são agregados.

O grid completo de fatores de pós-processamento compreende $2 \times 2 \times 4 \times 5 \times 3 = 240$ combinações básicas, expandidas para até 1920 configurações com fatores adicionais. Todas as combinações são avaliadas por reagregação dos mapas NLL previamente cacheados — a rede processa cada imagem em apenas 4 passagens (`pad` $\times$ `TTA`).

C. Estratégia de Ablação, Hipóteses e Regras de Decisão

Os fatores não foram tratados como hiperparâmetros intercambiáveis. A escolha de cada um partiu de uma pergunta operacional: a intervenção altera (i) a distribuição de features apresentada ao flow, (ii) a interpretação da NLL que o flow já produz, ou (iii) o registro espacial entre mapa e máscara? Fatores dos grupos (ii) e (iii) podem ser avaliados pós-hoc; fatores do grupo (i) exigem retreino e têm custo substancialmente maior. Essa distinção determina a ordem do estudo e evita atribuir a uma mudança de arquitetura um ganho produzido apenas pelo scoring.

O protocolo tem três estágios. Primeiro, uma *auditoria de compatibilidade* verifica que treino e avaliação usam a mesma arquitetura de atenção, `out_size`, `clamp_scale`, conjunto de níveis e estatísticas de `featnorm`. As heads legadas são úteis para medir o potencial de pós-processamento, mas não para inferir a informatividade intrínseca de um nível. Segundo, a *ablação pós-hoc pareada* varia `score_mode`, `padding`, TTA, níveis e σ sobre mapas de NLL cacheados. Um par difere somente no fator avaliado; head, imagens, condição de `padding`/TTA e demais opções são mantidos fixos. Terceiro, o *retreino focal* testa apenas escolhas que alteram a entrada ou a capacidade do flow: `featnorm`, `clamp_scale`, rotação, `padding` no treino e níveis treinados.

O retreino não é um fatorial completo. As 27 receitas constituem uma sequência de testes de hipóteses motivados pelos resultados pós-hoc e pelos diagnósticos por nível. Assim, deltas entre receitas são comparações dentro de cada rodada, e não estimativas independentes de todos os efeitos e interações. Esta limitação é intencional: um fatorial que combinasse todas as receitas de treino com todo o grid de inferência multiplicaria o custo sem aumentar proporcionalmente a evidência sobre decisões de implantação.

A configuração é escolhida apenas em `grid_val.csv`, com `margin=0`; o held-out é usado uma única vez no reporte final. A margem de borda foi retirada do grid porque pode inflar AUROC ao remover justamente a região em que o viés deve ser detectado. A variação observada de 0,0044 em Pixel AUROC entre dois held-outs do mesmo modelo é empregada como resolução prática: diferenças menores não sustentam um ranking entre receitas. AUROC, AP e AUPRO são avaliados conjuntamente; quando divergem, o score composto evita trocar cobertura regional por pequena melhora na ordenação global.

D. Protocolo Experimental

1) *Dataset*: O INSPLAD-seg [7] fornece imagens de 5 classes de componentes de linhas de transmissão com máscaras de segmentação de defeitos. As características de cada classe são apresentadas na Tabela II.

2) *Protocolo de Avaliação*: Como o INSPLAD-seg não fornece split de validação, o conjunto de teste é dividido estratificadamente com `val_fraction=0.4`: a porção de validação é usada para seleção de configuração, e o held-out restante é reportado uma única vez. A seed é fixa (42) para determinismo. Todas as imagens são redimensionadas para

448 × 448 px. A sensibilidade ao split foi medida diretamente: o mesmo modelo avaliado em held-outs de 108 e 92 imagens produziu $\Delta = 0,0044$ de AUROC, definindo o limiar de significância.

3) *Métricas*: Reportamos conjuntamente três métricas complementares:

- **Pixel AUROC**: área sob a curva ROC sobre todos os pixels de todas as imagens. Métrica principal de ordenação.
- **Pixel AP**: área sob a curva precisão-recall. Sensível à qualidade nas regiões de alto score.
- **AUPRO**: média por região conexa de defeito da fração coberta, integrada até FPR = 30%. Sensível a falsos positivos concentrados (viés de borda).

A utilização conjunta é metodologicamente necessária: AUROC alto com AP baixo é assinatura de desbalanceamento extremo; AUROC alto com AUPRO baixo indica falso positivo concentrado. Adicionalmente, Pixel AP não é comparável entre classes em valores absolutos — a razão AP/trivial é a medida relevante.

IV. RESULTADOS

A. Decomposição Incremental dos Ganhos

A Tabela III apresenta a cadeia incremental de ganhos sobre a configuração de produção original, adicionando uma técnica por vez na melhor head de cada classe. A ordem reflete o custo crescente de implementação.

O ganho total do pós-processamento atinge +0,0965 de AUROC médio sem nenhum retreino. Em *vari-grip*, o ganho é de +0,1757; em *glass-insulator*, +0,1664. Os passos de maior impacto são a troca para agregação `raw` (+0,0381 médio) e a seleção ótima de níveis (+0,0301 médio). Nenhuma receita de treinamento testada produz ganho comparável.

A Tabela IV consolida a síntese quantitativa multidimensional dos fatores investigados ao longo das ~24 000 medições experimentais nas 5 classes do benchmark.

B. Da Evidência à Receita de Implantação

Os valores incrementais da Tabela III descrevem o ganho acumulado de uma cadeia de decisões; não constituem efeitos causais isolados, pois cada passo é avaliado depois dos anteriores. A robustez de uma escolha é estabelecida pelos efeitos pareados da Tabela IV; a seleção de receita é feita no grid de validação; e a generalização é comunicada pelo held-out, que não participa da seleção. Essa separação evita interpretar um máximo de grid como evidência de generalização.

O primeiro resultado da auditoria foi uma correção metodológica. Em *glass-insulator*, a head legada indicava AUROC de 0,2583 para L1, aparentemente um sinal invertido. Depois de alinhar a receita de treino e avaliação, L1 atingiu 0,8740. Portanto, a observação legada foi tratada como artefato de incompatibilidade, não como evidência sobre a patologia; a interpretação de níveis foi feita exclusivamente em heads retreinadas com receita rastreável.

As forças de evidência não são homogêneas. `raw`, `padding` de inferência e TTA foram testados em pares sob múltiplas

Tabela I
RACIONAL DE INCLUSÃO E MÉTODO DE DECISÃO DOS FATORES ABLADOS.

Fator	Valores	Hipótese	Critério de decisão
score_mode	raw, min-max, prob., std.	A NLL contém escala absoluta; normalizar cada imagem pode eliminar informação entre amostras.	Comparação pós-hoc pareada em todas as classes.
levels	0, 1, 2, 01, 02, 12, 012	Uma escala não informativa pode diluir a NLL do nível dominante.	AUROC por nível, grid de validação e <i>regret</i> do default.
reflect_pad e TTA	0/112 px; nenhuma/4 vistas	Padding por zeros e prior posicional podem criar scores espúrios.	Efeito pareado, perfil de borda e AU-PRO; custo de inferência reportado separadamente.
σ	0, 2, 4, 8	O filtro deve reduzir ruído sem apagar defeitos cuja escala é pequena.	Seleção no grid de validação, condicionada à escala da patologia.
featnorm, clamp, rotação e pad no treino	ligado/desligado; clamp 0,5/1,9	A estabilidade e a expressividade do flow podem variar com a escala e a profundidade das features.	Retreino contra baseline da mesma rodada; AUROC, AP e AUPRO devem concordar.

Tabela II
CARACTERÍSTICAS DAS 5 CLASSES DO INSPLAD-SEG.

Classe	Treino	Teste	Anom.	% pixels
<i>vari-grip</i>	477	154	40	4,6%
<i>lightning-rod</i>	462	163	46	1,9%
<i>glass-insulator</i>	1 104	678	87	0,14%
<i>polymer-shackle</i>	935	317	82	3,1%
<i>yoke-suspension</i>	4 834	200	46	2,0%

configurações. Escolhas de treino foram comparadas em receitas específicas e, por isso, devem ser entendidas como condicionais à classe e à head. Essa distinção sustenta a separação, nas diretrizes finais, entre defaults robustos e escolhas que obrigatoriamente requerem validação local.

C. Superioridade da Agregação *raw*

A Tabela VI apresenta o ganho pareado de *raw* sobre *per_level_minmax* em cada classe, medido sobre todas as configurações que diferem *apenas* no modo de agregação.

O ganho é positivo em todas as 5 classes, com 76–100% dos pares individuais favorecendo *raw*. Este é o efeito isolado de maior magnitude do estudo. A explicação é direta: a normalização min-max por imagem destrói a escala absoluta da NLL, eliminando a comparabilidade entre imagens. A soma direta preserva essa informação, tornando o mapa de anomalia útil tanto para localização quanto para detecção em nível de imagem (Image AUROC via mapa: 0,41 com minmax vs. 0,76 com *raw* + *featnorm*).

O ganho pareado das demais técnicas de inferência é: TTA por flips +0,0120 (positivo em 76–97% dos pares em 4 classes, mas apenas 46% em *yoke*); reflect padding +0,0049 (70–85% dos pares).

D. Hierarquia dos Níveis de Features

A Tabela VII apresenta o Pixel AUROC de cada nível avaliado isoladamente (pad 112, flips, melhor head retreinada de cada classe).

Não existe hierarquia universal entre os níveis. L1 domina em *vari-grip* (defeitos de textura fina), L3 domina em

lightning-rod, *glass* e *yoke* (defeitos estruturais), e L2 é o melhor nível apenas em *polymer*. Em *vari-grip*, L1 isolado atinge 0,9191 de AUROC no teste completo, e a fusão com L3 *derruba* o desempenho em 0,063 (contaminação pelo nível inferior).

Apesar dessa diversidade, o conjunto *levels*=02 (L1+L3) apresenta *regret* notavelmente baixo quando fixado como default (Tabela VIII).

O *regret* é $\leq 0,0012$ em 4 de 5 classes. A exceção é *polymer* (*regret* 0,0278), a única classe em que L2 é o nível dominante. Portanto, *levels*=02 é um default seguro, exceto quando L2 contribui significativamente.

E. Não-Universalidade do *featnorm*

A normalização de features (*featnorm*) foi a intervenção de treinamento de maior impacto em *vari-grip* (+0,070 AUROC) e venceu em 2 de 5 classes. Entretanto, a Tabela IX demonstra que ela não generaliza.

Em *yoke-suspension*, *featnorm* produz o pior resultado do estudo inteiro: −0,0499 AUROC e −0,1226 AUPRO. O mecanismo explicativo é a concentração de sinal: a padronização por canal equaliza os 64 canais de L1, onde a informação discriminativa está concentrada em poucos canais de alta magnitude, beneficiando classes cujo sinal vive em L1 (*vari-grip*). Porém, em L2/L3 (192–256 canais majoritariamente não informativos), a mesma operação amplifica ruído. Em classes onde L3 domina (*yoke*, *lightning-rod*), esse efeito é prejudicial. Como consequência, *featnorm* foi rebaixada de “receita padrão” para “ligar somente após validar na classe”.

F. Reflect Padding como Técnica Exclusiva de Inferência

A *conv1* da AlexNet (kernel 11×11, padding 2) produz ativações de borda computadas predominantemente sobre pixels zero. O flow, treinado exclusivamente em imagens normais, marca essas ativações artificiais como anômalas, gerando um artefato de “borda quente” nos mapas. O reflect padding de 112 px na inferência substitui esses zeros por conteúdo espelhado, eliminando o artefato.

Criticamente, aplicar o mesmo padding durante o treinamento *piora* os resultados: na rodada 2, a head

Tabela III
CADEIA INCREMENTAL DE GANHOS DE PÓS-PROCESSAMENTO (PIXEL AUROC NO GRID DE VALIDAÇÃO).

Passo	<i>vari-grip</i>	<i>lightning-rod</i>	<i>glass</i>	<i>polymer</i>	<i>yoke</i>	Média
0. Produção (pad 0, sem TTA, minmax, L=012, $\sigma=4$)	0,7373	0,8008	0,7935	0,8651	0,8803	—
1. + <code>reflect_pad 112</code>	0,7407	0,8052	0,8253	0,8672	0,8785	+0,0080
2. + TTA flips	0,7955	0,8306	0,8240	0,8736	0,8794	+0,0173
3. + <code>score_mode raw</code>	0,8186	0,8625	0,9339	0,8901	0,8888	+0,0381
4. + seleção de níveis (melhor da classe)	0,9007	0,8798	0,9598	0,8901	0,9140	+0,0301
5. + σ ótimo da classe	0,9130	0,8810	0,9599	0,8901	0,9156	+0,0031
Ganho total	+0,1757	+0,0802	+0,1664	+0,0250	+0,0353	+0,0965

Tabela IV
SÍNTESE EXAUSTIVA DOS FATORES DE INFERÊNCIA, RETREINO E DINÂMICA MULTIESCALA NAS 5 CLASSES DO INSPLAD-SEG.

Dimensão Avaliada	Fator / Métrica	<i>vari-grip</i>	<i>lightning-rod</i>	<i>glass</i>	<i>polymer</i>	<i>yoke</i>	Média Geral
Ponto de Partida vs. Final	Baseline Produção (AUROC)	0,7373	0,8008	0,7935	0,8651	0,8803	0,8154
	Melhor Pós-processamento (AUROC)	0,9130	0,8810	0,9599	0,8901	0,9156	0,9120 (+0,0965)
Ganhos Pareados (Δ AUROC)	raw vs. minmax	+0,0574	+0,0794	+0,0441	+0,0205	+0,0471	+0,0497 (92,7% pos)
	tta flips vs. none	+0,0163	+0,0223	+0,0126	+0,0058	+0,0031 (46%)	+0,0120 (78,8% pos)
	pad 112 vs. pad 0	+0,0136	+0,0056	+0,0028	+0,0024	+0,0002	+0,0049 (76,4% pos)
Impacto do <code>featnorm</code>	Δ Pixel AUROC (vs. baseline)	+0,0440	−0,0107	+0,0396	−0,0066	−0,0499	−0,0067 (Não universal)
	Δ AUPRO (vs. baseline)	+0,0821	−0,0455	+0,0254	+0,0502	−0,1226	−0,0021 (Destrutivo em Yoke)
Dinâmica de Níveis	AUROC isolado: L1 / L2 / L3	0,893 / 0,817 / 0,787	0,760 / 0,807 / 0,877	0,874 / 0,650 / 0,942	0,776 / 0,880 / 0,841	0,852 / 0,798 / 0,879	L3 vence em 3/5
	Melhor subconjunto	0 (L1)	2 (L3)	02 (L1+L3)	012 (Todos)	02 (L1+L3)	—
	Regret com <code>levels=02</code>	0,0006	0,0012	0,0000	0,0278	0,0000	≤ 0,0012 em 4/5 classes
Treinamento e Overfitting	Época de Pico (de 80 épocas)	Época 16	Época 12	Época 36	Época 56	Época 4	Pico precoce em bases grandes
	Queda Pico → Época 80	−0,0123	−0,0012	−0,0009	−0,0002	−0,0299	Sobreajuste severo em yoke

Tabela V
RASTREABILIDADE DAS DECISÕES DE ABLAÇÃO ATÉ A RECEITA FINAL.

Decisão	Motivação	Evidência observada	Disposição final
NLL raw	Preservar comparabilidade entre imagens.	Maior ganho pareado: +0,0497 AUROC; 82–100% de pares positivos.	Default para as heads avaliadas.
Padding só na inferência	Substituir borda com zeros sem ensinar o espelhamento como normal.	+0,0049 pareado; pad no treino caiu de 0,9185 para 0,9033 no teste controlado.	<code>reflect_pad=112</code> na inferência; desligado no treino.
TTA como trade-off	Reduzir assimetria do prior posicional.	+0,0120 médio; em <i>yoke</i> , 46% dos pares favorecem TTA.	Ativo offline; opcional sob restrição de latência.
Seleção de níveis	Evitar ruído de escalas irrelevantes.	L1 domina <i>vari-grip</i> , L3 domina três classes e L2 domina <i>polymer</i> .	02 é default de baixo regret; revalidar por classe/head.
<code>featnorm</code> seletivo	Testar estabilização sem supor universalidade.	Benefício em <i>vari-grip</i> e <i>glass</i> ; −0,0499 AUROC e −0,1226 AUPRO em <i>yoke</i> .	Desligado por default; requer validação por classe.
Checkpoint em vez de época fixa	Evitar confundir redução da loss com generalização.	<i>Yoke</i> teve pico na época 4 e queda de 0,0299 até a 80.	Orçamentos por classe, early stopping e score composto.

Tabela VI
GANHO PAREADO DE RAW VS. `PER_LEVEL_MINMAX` POR CLASSE.

Classe	Ganho médio	% pares positivos	<i>n</i> pares
<i>vari-grip</i>	+0,0574	97%	624
<i>lightning-rod</i>	+0,0794	100%	192
<i>glass-insulator</i>	+0,0441	100%	192
<i>polymer-shackle</i>	+0,0205	82%	72
<i>yoke-suspension</i>	+0,0471	97%	72
Média	+0,0497	76–100%	—

`featnorm_pad112` (treinada com pad) obteve Pixel AUROC de 0,9033 contra 0,9185 da `featnorm` (treinada sem pad) — a pior das cinco variantes. O flow gasta capacidade modelando o conteúdo espelhado — que não é uma ima-

gem plausível — como se fosse normal. Na inferência, o mesmo padding apenas substitui zeros (ainda menos plausíveis) por algo mais próximo da distribuição de treinamento. Esta é uma exceção documentada à regra de “coerência treino–avaliação”, que continua válida para `clamp_scale`, `out_size`, `levels` e `feat_norm`.

G. Dinâmica de Overfitting do Flow

A Tabela X documenta o pico precoce e a degradação subsequente da Pixel AUROC ao longo do treinamento.

O overfitting é severo em *yoke-suspension*: com 4834 imagens normais (a maior base), o pico ocorre na época 4 — antes mesmo do fim do warmup de 5 épocas do cosine schedule — e degrada −0,030 até a época 80. Em 85% das avaliações (17 de 20), o AUROC estava acima do valor

Tabela VII
AUROC ISOLADO POR NÍVEL DE FEATURES NAS 5 CLASSES (PAD 112, FLIPS).

Nível	<i>vari-grip</i>	<i>lightning-rod</i>	<i>glass</i>	<i>polymer</i>
L1 (64ch)	0,893	0,760	0,874	0,776
L2 (192ch)	0,817	0,807	0,650	0,880
L3 (256ch)	0,787	0,877	0,942	0,841
Melhor conj.	0	2	02	012

Nível	<i>yoke</i>	Melhor?
L1	0,852	1/5
L2	0,798	1/5
L3	0,879	3/5
Melhor conj.	02	

Tabela VIII
REGRET DE FIXAR LEVELS = 02 COMO DEFAULT (MELHOR CONFIG COM 02 VS. MELHOR CONFIG GLOBAL NO GRID DE VALIDAÇÃO).

Classe	Melhor conj.	AUROC (melhor)	Regret
<i>vari-grip</i>	0	0,9130	0,0006
<i>lightning-rod</i>	012	0,9012	0,0012
<i>glass-insulator</i>	02	0,9645	0,0000
<i>yoke-suspension</i>	02	0,9156	0,0000
<i>polymer-shackle</i>	012	0,8901	0,0278

final. As demais classes são estáveis após convergência. Este resultado motivou a implementação de early stopping com `-patience` e a definição de orçamentos de épocas específicos por classe. O erro de sobrescrever esses orçamentos com uma flag `-epochs` global uniforme degrada classes massivas.

H. Correção do AUPRO e Métricas Compostas

Um bug na função `compute_aupro` gerava limiares com `np.linspace(min, max, 200)`. Em mapas de NLL crua com caudas pesadas, outliers esticavam o intervalo linear, fazendo com que ~ 199 dos 200 limiares caíssem em regiões

Tabela IX
IMPACTO DO FEATNORM POR CLASSE (MELHOR HEAD FEATNORM VS. MELHOR BASELINE, HELD-OUT).

Classe	Δ AUROC	Δ AUPRO
<i>glass-insulator</i>	+0,0396	+0,0254
<i>polymer-shackle</i>	-0,0066	+0,0502
<i>lightning-rod</i>	-0,0107	-0,0455
<i>yoke-suspension</i>	-0,0499	-0,1226

Tabela X
PICO DE TREINAMENTO E OVERFITTING DO FLOW POR CLASSE (80 ÉPOCAS).

Classe	Pico (época)	AUROC pico	AUROC ep. 80	Queda
<i>yoke</i>	4	0,9292	0,8993	-0,0299
<i>vari-grip</i>	16	0,8385	0,8262	-0,0123
<i>lightning-rod</i>	12	0,8365	0,8353	-0,0012
<i>glass</i>	36	0,9460	0,9451	-0,0009
<i>polymer</i>	56	0,8761	0,8759	-0,0002

com $FPR > 0,3$, retornando $AUPRO = 0,0000$ silenciosamente. A correção substitui os limiares lineares por *quantis dos pixels normais* no intervalo $[1 - \max_fpr, 1, 0]$:

$$\text{thresholds} = \text{quantile}(\text{scores}_{\text{normal}}, \text{linspace}(1 - \max_fpr, 1, 0, 200)) \quad (3)$$

Este cálculo é invariante a outliers arbitrários e a reescalas monótonas, resolvendo o problema para qualquer distribuição de scores.

Do RD++ [6], transferimos o score composto $(AUROC_{px} + AUROC_{sp} + AUPRO)/3$ para seleção de checkpoints, protegendo contra otimização de critério único. Também incorporamos a persistência de `history.json` a cada época e early stopping por `-patience`.

I. Resultados Consolidados

A Tabela XI apresenta os melhores resultados por classe com a receita de implantação validada.

As melhorias variam de +0,018 (*polymer*) a +0,156 (*vari-grip*) em Pixel AUROC e de +0,019 a +0,154 em AUPRO. Nota-se a dissociação entre localização e detecção: *glass-insulator* tem o melhor Pixel AUROC (0,9560) e o pior Image AUROC (0,7706); *yoke-suspension* apresenta o padrão oposto. As duas cabeças (SEDifferNet para imagem, CFLOW para pixel) falham por motivos independentes.

A Tabela XII compara os resultados com o RD++ [6] (WideResNet-50 + projeção multi-escala).

O pipeline DifferNet com pós-processamento completo supera o RD++ em Pixel AUROC em 2 de 4 classes avaliadas, e em AUPRO em 1 de 4. O RD++ leva vantagem em AUPRO por treinar explicitamente com perda de localização e pseudo-anomalias via ruído simplex.

V. DISCUSSÃO

A. Por que o Pós-Processamento Domina

O resultado central deste estudo — que o pós-processamento contribui com mais AUROC do que qualquer intervenção de treinamento — admite uma interpretação direta fundamentada na teoria de Normalizing Flows. O backbone (SEDifferNet) é congelado; todo o poder representacional para localização reside nas features que ele já produz. O que o pós-processamento faz é *alinhar a forma como o scoring interpreta essas features* com a tarefa de localização. A densidade $p(\mathbf{x})$ estimada pelo flow possui significado probabilístico exato; a soma direta das NLLs ($\sum_k -\log p(\mathbf{x}_k)$) equivale matematicamente a modelar a verossimilhança conjunta sob a hipótese de independência condicional entre os níveis, preservando a calibração métrica global entre imagens normais e anômalas. Em contraste, a agregação `per_level_minmax`, herdada do CFLOW-AD, destrói a escala absoluta ao normalizar cada mapa individualmente para o intervalo $[0, 1]$, forçando toda imagem puramente normal a conter um falso positivo com score 1,0.

Além disso, o modo `per_level_prob` do CFLOW-AD original ($\exp(\text{logsigmoid}(-\text{NLL})/C)$) satura na presença de ativações ReLU não limitadas de AlexNet, onde magnitudes

Tabela XI
MELHOR RESULTADO POR CLASSE (HELD-OUT, $\text{val_fraction} = 0.4$, CONFIGURAÇÃO ESCOLHIDA NA VALIDAÇÃO). TODAS USAM $\text{REFLECT_PAD 112} + \text{TTA FLIPS} + \text{SCORE_MODE RAW}$.

Classe	Receita vencedora	Níveis	σ	Pixel AUROC	Pixel AP	AUPRO	Img. AUROC
<i>glass-insulator</i>	featnorm_clamp19	02	2	0,9560	0,0063 (35×)	0,7604	0,7706
<i>vari-grip</i>	featnorm_clamp19	01	8	0,9270	0,1147 (9,5×)	0,7585	0,9044
<i>yoke-suspension</i>	baseline	02	8	0,9188	0,0568 (10×)	0,6611	0,9744
<i>lightning-rod</i>	baseline	2	4	0,8815	0,0251 (4,6×)	0,5642	0,9485
<i>polymer-shackle</i>	baseline	012	8	0,8806	0,0282	0,5943	0,9495
Produção original (média)				0,8313	—	0,5349	—
Melhor obtido (média)				0,9128	—	0,6677	—

Tabela XII
COMPARAÇÃO DIFFERNET (PÓS-PROCESSAMENTO COMPLETO) VS. RD++.

Classe	Pixel AUROC		AUPRO	
	RD++	Ours	RD++	Ours
<i>glass</i>	0,9368	0,9534	0,7560	0,6591
<i>polymer</i>	0,9024	0,8505	0,6508	0,5933
<i>vari-grip</i>	0,8588	0,9191	0,5366	0,7621
<i>yoke</i>	0,9708	0,9348	0,7328	0,6686

de NLL na ordem de centenas comprimem a saída para valores próximos a zero ou um, explicando seu desempenho inferior (média 0,6992).

A seleção de níveis opera de forma análoga: fusionar indiscriminadamente os três níveis dilui o sinal do nível dominante com o ruído dos inferiores. Em *vari-grip*, fusionar L1 (AUROC 0,9191) com L3 (0,8052) derruba o resultado para 0,8561 — uma perda de $-0,063$. Esse efeito é invisível em benchmarks onde a hierarquia é consistente entre classes.

B. Implicações para a Comunidade de Detecção de Anomalias

Três implicações emergem para a comunidade mais ampla:

(i) *Trabalhos que reportam apenas métricas finais sem decompor as contribuições de arquitetura, treinamento e pós-processamento escondem a origem real do ganho.* Em nosso caso, $\sim 70\%$ do ganho em *lightning-rod* é pós-processamento puro. Isso sugere que comparações entre métodos que utilizam pós-processamentos diferentes podem atribuir ao modelo diferenças que são, na verdade, de scoring.

(ii) *A fusão multi-escala fixa — padrão em CFLOW-AD, PaDiM e PatchCore — carrega pelo menos um nível que não contribui em nenhuma das 5 classes.* O conjunto L1+L3 ($\text{levels} = 02$) tem $\text{regret} \leq 0,0012$ em 4 de 5 classes e reduz os parâmetros da head em $\sim 20\%$.

(iii) *Técnicas de normalização de features que funcionam em um benchmark ou uma classe não devem ser adotadas como receita universal.* O *featnorm* é um exemplo instrutivo: excelente em *glass* ($+0,0396$), catastrófico em *yoke* ($-0,0499$). O mecanismo subjacente — concentração de sinal em L1 com degradação de L2/L3 — é previsível a partir da teoria, mas só foi observado porque o estudo cobriu 5 classes com hierarquias de níveis distintas.

C. O Perigo dos Checkpoints Legados

A lição metodológica mais custosa do estudo é que checkpoints legados produzem diagnósticos enganosos sobre a informatividade das features. Em *glass-insulator*, o nível L1 media AUROC 0,2583 na head publicada — aparentemente anticorrelacionado com as anomalias — e 0,8740 após retreino com a receita corrigida. A diferença de $+0,6157$ não se devia a uma propriedade física da classe, mas a divergências silenciosas entre os hiperparâmetros de treinamento e avaliação da head legada (clamp scale, caminho de atenção, modo de agregação). Uma “explicação física” inteiramente construída sobre esse artefato foi invalidada pelo retreino. Este resultado adverte que ablations conduzidos sobre modelos de terceiros — prática comum na literatura — podem produzir conclusões sistematicamente incorretas se os hiperparâmetros de scoring não forem coerentes.

D. Limitações

O estudo possui limitações que devem ser consideradas na interpretação:

- **Backbone único.** Todos os resultados utilizam AlexNet com atenção SE. Embora a superioridade teórica da NLL *raw* decorra de propriedades intrínsecas a Normalizing Flows (não do extrator), backbones mais profundos (ResNet, WideResNet, EfficientNet) podem alterar a hierarquia entre níveis de features.
- **Dataset único.** O INSPLAD-seg tem características específicas (fundo natural de vegetação, proporções baixas de anomalia) que podem interagir com os hiperparâmetros de suavização e padding.
- **Sem validação cruzada entre datasets.** As descobertas ainda não foram estendidas para o MVTec-AD ou VisA, demandando validação externa complementar.
- **Limiar de significância baseado em um par de splits.** A variação de 0,0044 AUROC entre splits foi medida com uma troca controlada de *val_fraction*; embora funcional para descartar ruído, o uso de múltiplos seeds aleatórios representa o padrão-ouro estatístico.
- **Dinâmica de learning rate no overfitting.** O pico precoce na época 4 em *yoke* sugere que a taxa de aprendizado padrão (2×10^{-4}) pode ser excessiva para bases com milhares de amostras, abrindo oportunidade para escalas de lr inversamente proporcionais ao tamanho do dataset.

- **Hiperparâmetros do flow não ablados.** O número de blocos ($K = 8$), a dimensão oculta (256) e a dimensão do PE (64) foram mantidos nos defaults do projeto sem ablação.

E. Diretrizes de Implantação e Trade-off de Latência

Com base nos resultados consolidados, estabelecemos o seguinte protocolo prático de implantação:

- 1) **Sempre** (pós-hoc, sem retreino): `score_mode=raw` (+0,0497, maior efeito e custo computacional nulo) e `reflect_pad112` (só na inferência).
- 2) **Trade-off de latência para TTA:** O TTA por flips adiciona +0,0120 AUROC na média, mas quadruplica o número de passagens pela rede ($4\times$ tempo de inferência). Em sistemas embarcados de VANT com restrição severa de tempo real, o TTA pode ser desligado com perda modesta de acurácia, enquanto em inspeções em lote offline ele deve permanecer ativado.
- 3) **Default seguro de níveis e escala:** `levels=02` (L1+L3), $\sigma = 8$ para defeitos $\geq 1\%$ da área, $\sigma = 2$ para micro-defeitos estruturais $< 0,5\%$.
- 4) **Política de normalização de treino (risco assimétrico):** `featnorm` deve permanecer desativado por padrão; o ganho moderado em classes favoráveis (+0,039 a +0,044) não compensa o risco de colapso severo em componentes dominados por contexto semântico global ($-0,0499$ AUROC e $-0,1226$ AUPRO em *yoke*). Ligue-o apenas para componentes onde a patologia resida comprovadamente em características rasas de cor e textura (L_1).
- 5) **Seleção de checkpoint no treino:** por score composto ($AUROC_{px} + AUROC_{img} + AUPRO$)/3 e com agregação `raw` durante a validação in-training.

VI. CONCLUSÃO

Este trabalho apresentou um estudo de ablação abrangente da cabeça de normalizing flow condicional para localização de anomalias em 5 classes do benchmark INSPLAD-seg, totalizando $\sim 24\,000$ medições. A principal descoberta é que o pós-processamento — uma cadeia de intervenções na inferência que não requer nenhum retreino — contribui com +0,0965 de Pixel AUROC médio, superando qualquer intervenção de treinamento. A agregação `raw` das NLLs é o efeito isolado de maior magnitude (+0,0497), universalmente benéfico nas 5 classes.

O estudo revelou que a hierarquia entre níveis de features não é universal (L1 domina em defeitos de textura, L3 em defeitos estruturais), que a normalização de features por canal não generaliza (prejudicial em 1 de 5 classes), e que o reflect padding é uma técnica exclusiva de inferência — aplicá-lo no treinamento piora os resultados. Adicionalmente, demonstrou que checkpoints legados produzem diagnósticos sistematicamente enganosos sobre features, invalidando conclusões construídas sobre eles.

Trabalhos futuros incluem: (i) padronização seletiva por nível (`featnorm` restrita a L1), cujo mecanismo identificado

neste estudo prediz resolver o caso *yoke*; (ii) substituição do reflect padding por replicate padding para evitar eco de estruturas; (iii) validação cruzada em MVTec-AD e outros benchmarks para medir a generalização das descobertas; e (iv) supressão de fundo por máscara de objeto, o item de diagnóstico de maior potencial remanescente.

REFERÊNCIAS

- [1] M. Rudolph, B. Wandt e B. Rosenhahn, “Same Same But DifferNet: Semi-Supervised Defect Detection with Normalizing Flows,” in *Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV)*, 2021, pp. 1907–1916.
- [2] D. Gudovskiy, S. Ishizaka e K. Kozuka, “CFLOW-AD: Real-Time Unsupervised Anomaly Detection with Localization via Conditional Normalizing Flows,” in *Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV)*, 2022, pp. 1819–1828.
- [3] M. Rudolph, T. Wehrbein, B. Rosenhahn e B. Wandt, “Fully Convolutional Cross-Scale-Flows for Image-based Defect Detection,” in *Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV)*, 2022, pp. 1088–1097.
- [4] T. Defard, A. Setkov, A. Loesch e R. Audigier, “PaDiM: a Patch Distribution Modeling Framework for Anomaly Detection and Localization,” in *Proc. Int. Conf. Pattern Recognition (ICPR) Workshops*, 2021, pp. 475–489.
- [5] K. Roth, L. Pemula, J. Zepeda, B. Schölkopf, T. Brox e P. Gehler, “Towards Total Recall in Industrial Anomaly Detection,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 14318–14328.
- [6] H. Deng e X. Li, “Anomaly Detection via Reverse Distillation from One-Class Embedding,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 9737–9746.
- [7] A. L. B. Vieira-e-Silva *et al.*, “InsPLAD: A Dataset and Benchmark for Power Line Asset Inspection in UAV Images,” *Int. J. Remote Sensing*, vol. 44, no. 23, pp. 7465–7484, 2023.
- [8] Y. Zhou, X. Xu, J. Song, F. Shen e H. T. Shen, “MSFlow: Multiscale Flow-based Framework for Unsupervised Anomaly Detection,” *IEEE Trans. Neural Networks and Learning Systems*, 2024.
- [9] B. Alsallakh, N. Kokhlikyan, V. Miglani, J. Yuan e O. Reblitz-Richardson, “Mind the Pad – CNNs can Develop Blind Spots,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2021.
- [10] M. A. Islam, S. Jia e N. D. B. Bruce, “How Much Position Information Do Convolutional Neural Networks Encode?” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2020.
- [11] R. Geirhos, P. Rubisch, C. Michaelis, M. Bethge, F. A. Wichmann e W. Brendel, “ImageNet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2019.
- [12] O. S. Kayhan e J. C. van Gemert, “On Translation Invariance in CNNs: Convolutional Layers Can Exploit Absolute Spatial Location,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 14274–14285.